

Вопросы к экзамену по предмету: "Технологии анализа больших данных"

Вопрос 1: Какое из следующих утверждений о драйвере Spark неверно?

- А. Драйвер Spark - это узел, в котором выполняется главный метод приложения Spark для координации работы приложения.
- В. Драйвер Spark горизонтально масштабируется для увеличения общей пропускной способности обработки.
- С. Драйвер Spark содержит объект SparkContext.
- D. Драйвер Spark отвечает за планирование выполнения данных различными рабочими узлами в кластерном режиме.
- Е. Для оптимальной производительности драйвер Spark должен располагаться как можно ближе к рабочим узлам.

Вопрос 2: Что из нижеперечисленного описывает узлы в Spark в кластерном режиме?

- А. Узлы являются самым детальным уровнем выполнения в иерархии выполнения Spark.
- В. Существует только один узел, на котором размещаются драйвер и исполнители.
- С. Узлы - это другое название исполнителей, поэтому они представляют собой экземпляры движка обработки для выполнения вычислений.
- D. Существуют узлы драйвера и рабочие узлы, оба из которых могут масштабироваться горизонтально.
- Е. Рабочие узлы - это машины, на которых размещаются исполнители, отвечающие за выполнение задач.

Вопрос 3: Какое из следующих утверждений о слотах верно?

- А. Слотов должно быть больше, чем исполнителей.
- В. Должно быть больше задач, чем слотов.
- С. Слоты являются самым детальным уровнем выполнения в иерархии выполнения Spark.

- D. Слоты не используются в кластерном режиме.
- E. Слоты - это ресурсы для параллелизма внутри приложения Spark.

Вопрос 4: Что из перечисленного ниже является комбинацией блока данных и набора трансформаторов, которые будут выполняться на одном исполнителе?

- A. Исполнитель
- B. Узел
- C. Задание (Job)
- D. Задача (Task)
- E. Слот

Вопрос 5: Что из нижеперечисленного представляет собой группу задач, которые могут выполняться параллельно для вычисления одного и того же набора операций на потенциально нескольких машинах?

- A. Задание (Job)
- B. Слот
- C. Исполнитель
- D. Задача (Task)
- E. Стадия (Stage)

Вопрос 6: Что из нижеперечисленного описывает перемешивание (shuffle)?

- A. Перемешивание - это процесс перераспределения данных между разделами.
- B. Перемешивание - это процесс перераспределения данных между исполнителями.
- C. Перемешивание - это процесс распределения разделов между задачами.
- D. Перемешивание - это процесс упорядочивания разделов для записи.
- E. Перемешивание - это процесс упорядочивания задач для выполнения.

Вопрос 7: DataFrame df очень большой с большим количеством разделов, больше, чем исполнителей в кластере. Исходя из этой ситуации, что из нижеперечисленного является неверным?

Предположим, что на один исполнитель приходится одно ядро.

- A. Производительность будет ниже оптимальной, потому что не все исполнители будут использоваться одновременно.
- B. Производительность будет ниже оптимальной, потому что не все данные могут быть обработаны одновременно.
- C. При вызове операций, вызывающих перемешивание, на DataFrame df будет выполняться большое количество соединений перемешивания.
- D. Будет много накладных расходов, связанных с управлением ресурсами для обработки данных в каждой задаче.
- E. Может возникнуть риск ошибок нехватки памяти в зависимости от размера исполнителей в кластере.

Вопрос 8: Какая из следующих операций является действием (action)?

- A. DataFrame.filter()
- B. DataFrame.distinct()
- C. DataFrame.intersect()
- D. DataFrame.join()
- E. DataFrame.count()

Вопрос 9: Что из нижеперечисленного описывает разницу между преобразованиями (transformations) и действиями (actions)?

- A. Преобразования работают с DataFrames/Datasets, а действия предназначены для объектов нативного языка.
- B. Нет никакой разницы между действиями и преобразованиями.
- C. Действия - это операции бизнес-логики, которые не вызывают выполнения, в то время как преобразования - это триггеры выполнения, ориентированные на возвращение результатов.
- D. Действия работают с DataFrames/Datasets, а преобразования предназначены для объектов нативного языка.

- Е. Преобразования - это операции бизнес-логики, которые не вызывают выполнения, в то время как действия - это триггеры выполнения, ориентированные на возвращение результатов.


Вопрос 10: Какая из следующих операций с DataFrame всегда классифицируется как узкое преобразование (narrow transformation)?

- A. DataFrame.sort()
- B. DataFrame.distinct()
- C. DataFrame.repartition()
- D. DataFrame.select()
- E. DataFrame.join()

Вопрос 11: Spark имеет несколько различных режимов выполнения/развертывания: кластерный, клиентский и локальный. Что из нижеперечисленного описывает режим выполнения/развертывания Spark?

- A. Режим выполнения/развертывания Spark определяет, где физически расположены драйвер и исполнители при запуске Spark-приложения.
- B. Режим выполнения/развертывания Spark определяет, какие задачи назначаются каким исполнителям в кластере.
- C. Режим выполнения/развертывания Spark определяет, какой узел в кластере узлов отвечает за запуск программы драйвера.
- D. Режим выполнения/развертывания Spark определяет, к скольким узлам драйвер будет подключаться при запуске Spark-приложения.
- E. Режим выполнения/развертывания Spark определяет, выполняются ли результаты интерактивно в среде блокнота или в пакетном режиме.

Вопрос 12: Какая из следующих конфигураций кластера обеспечит завершение Spark-приложения в случае отказа рабочего узла? Обратите внимание, что каждая конфигурация имеет примерно одинаковую вычислительную мощность, используя 100 ГБ оперативной памяти и 200 ядер.



- А. Сценарий №1
- В. Все конфигурации должны обеспечивать завершение, поскольку рабочие узлы отказоустойчивы.
- С. Сценарий №4
- D. Сценарий №5
- E. Сценарий №6

Вопрос 13: Что из нижеперечисленного описывает ошибки нехватки памяти (out-of-memory errors) в Spark?

- А. Ошибка нехватки памяти возникает, когда драйверу или исполнителю не хватает памяти для сбора или обработки данных, выделенных ему.
- В. Ошибка нехватки памяти возникает, когда уровень хранения Spark слишком лоялен и позволяет кэшировать объекты данных как в памяти, так и на диске.
- С. Ошибка нехватки памяти возникает, когда задач больше, чем исполнителей, независимо от количества рабочих узлов.
- D. Ошибка нехватки памяти возникает, когда Spark-приложение вызывает слишком много преобразований подряд, не вызывая действия, независимо от размера объекта данных, на котором выполняются преобразования.

- Е. Ошибка нехватки памяти возникает, когда драйверу выделено слишком много памяти для вычислительных целей.

Вопрос 14: Какой из следующих уровней хранения является значением по умолчанию для `persist()` для не-потокowego `DataFrame/Dataset`?

- А. `MEMORY_AND_DISK` (Память и диск)
- В. `MEMORY_AND_DISK_SER` (Память и сериализованный на диск)
- С. `DISK_ONLY` (Только диск)
- D. `MEMORY_ONLY_SER` (Только память, сериализованный)
- Е. `MEMORY_ONLY` (Только память)

Вопрос 15: Что из нижеперечисленного описывает широкопередателъную переменную (`broadcast variable`)?

- А. Широкопередателъная переменная - это объект Spark, который необходимо разделить на несколько рабочих узлов, потому что он слишком большой, чтобы поместиться на одном рабочем узле.
- В. Широкопередателъная переменная может быть создана только явным вызовом операции `broadcast()`.
- С. Широкопередателъная переменная полностью кэшируется на узле драйвера, поэтому ей не нужно присутствовать на каких-либо рабочих узлах.
- D. Широкопередателъная переменная полностью кэшируется на каждом рабочем узле, поэтому ее не нужно передавать или перемешивать между узлами на каждом этапе.
- Е. Широкопередателъная переменная сохраняется на диске каждого рабочего узла для легкого считывания в память по мере необходимости.

Вопрос 16: Какая из следующих операций с наибольшей вероятностью приведет к перекосу (`skew`) в размере разделов ваших данных?

- А. `DataFrame.collect()`
- В. `DataFrame.cache()`
- С. `DataFrame.repartition(n)`
- D. `DataFrame.coalesce(n)`

- E. DataFrame.persist()

Вопрос 17: На каких структурах данных построены Spark DataFrames?

- A. Массивы
- B. Строки
- C. RDD (Resilient Distributed Datasets - Устойчивые распределенные наборы данных)
- D. Векторы
- E. SQL Таблицы

Вопрос 18: Какой из следующих кодовых блоков возвращает DataFrame, содержащий только столбцы storeId и division из DataFrame storesDF?

storeId	open	openDate	division	sqft	numberOfEmployees	customerSatisfaction
0	true	1100746394	Utah	43161	61	71.1
1	true	944572255	West Virginia	18132	96	43.46
2	false	925495628	West Virginia	79520	45	36.93
3	true	1397353092	Texas	47751	78	47.19
4	true	986505057	Delaware	81483	95	25.24
...	...	...	...	...	...	...

Варианты ответа:

- A. storesDF.select("storeId").select("division")
- B. storesDF.select(storeId, division)
- C. storesDF.select("storeId", "division")
- D. storesDF.select(col("storeId", "division"))
- E. storesDF.select(storeId).select(division)

Вопрос 19: Какой из следующих блоков кода возвращает DataFrame, содержащий все столбцы из DataFrame storesDF, кроме столбцов sqft и customerSatisfaction?

storeId	open	openDate	division	sqft	numberOfEmployees	customerSatisfaction
0	true	1100746394	Utah	43161	61	71.1
1	true	944572255	West Virginia	18132	96	43.46
2	false	925495628	West Virginia	79520	45	36.93
3	true	1397353092	Texas	47751	78	47.19
4	true	986505057	Delaware	81483	95	25.24
...	...	...	...	...	...	...

Варианты ответа:

- A. storesDF.drop("sqft", "customerSatisfaction")
- B. storesDF.select("storeId", "open", "openDate", "division")
- C. storesDF.select(-col(sqft), -col(customerSatisfaction))
- D. storesDF.drop(sqft, customerSatisfaction)
- E. storesDF.drop(col(sqft), col(customerSatisfaction))

Вопрос 20: В приведенном ниже блоке кода есть ошибка. Этот блок кода предназначен для возвращения DataFrame, содержащего только строки из DataFrame storesDF, где значение в столбце "sqft" DataFrame storesDF меньше или равно 25 000. Предположим, что DataFrame storesDF - единственная определенная языковая переменная. Определите ошибку.

storeId	open	openDate	division	sqft	numberOfEmployees	customerSatisfaction
0	true	1100746394	Utah	43161	61	71.1
1	true	944572255	West Virginia	18132	96	43.46
2	false	925495628	West Virginia	79520	45	36.93
3	true	1397353092	Texas	47751	78	47.19
4	true	986505057	Delaware	81483	95	25.24
...	...	...	...	...	...	...

```
storesDF.filter(sqft <= 25000)
```


- A. Имя столбца sqft нужно взять в кавычки, например `storesDF.filter("sqft" <= 25000)`.
- B. Имя столбца sqft нужно взять в кавычки и обернуть в функцию `col()`, например `storesDF.filter(col("sqft") <= 25000)`.
- C. Знак в логическом условии внутри `filter()` нужно изменить с `<=` на `>`.
- D. Знак в логическом условии внутри `filter()` нужно изменить с `<=` на `>=`.
- E. Имя столбца sqft нужно обернуть в функцию `col()` следующим образом `storesDF.filter(col(sqft) <= 25000)`.

Вопрос 21: Приведенный ниже блок кода должен возвращать `DataFrame`, содержащий только строки из `DataFrame storesDF`, где значение в столбце `sqft` меньше или равно 25 000 ИЛИ значение в столбце `customerSatisfaction` больше или равно 30. Выберите ответ, который правильно заполняет пропущенные номера в блоке кода для выполнения этой задачи.

storeId	open	openDate	division	sqft	numberOfEmployees	customerSatisfaction
0	true	1100746394	Utah	43161	61	71.1
1	true	944572255	West Virginia	18132	96	43.46
2	false	925495628	West Virginia	79520	45	36.93
3	true	1397353092	Texas	47751	78	47.19
4	true	986505057	Delaware	81483	95	25.24
...	...	...	...	...	...	...

```
storesDF.__1__(__2__ __3__ __4__)
```

Варианты ответа:

- A.
 - a. `filter`
 - b. `(col("sqft") <= 25000)`
 - c. `|`
 - d. `(col("customerSatisfaction") >= 30)`
- B.
 - a. `drop`
 - b. `(col(sqft) <= 25000)`

- c. |
 - d. (col(customerSatisfaction) >= 30)
- C.
 - a. filter
 - b. col("sqft") <= 25000
 - c. |
 - d. col("customerSatisfaction") >= 30
- D.
 - a. filter
 - b. col("sqft") <= 25000
 - c. or
 - d. col("customerSatisfaction") >= 30
- E.
 - a. filter
 - b. (col("sqft") <= 25000)
 - c. or
 - d. (col("customerSatisfaction") >= 30)

Вопрос 22: Какая из следующих операций может быть использована для преобразования столбца DataFrame из одного типа в другой тип?

Варианты ответа:

- A. col().cast()
- B. convert()
- C. castAs()
- D. col().coerce()
- E. col()

Вопрос 23: Какой из следующих блоков кода возвращает новый DataFrame с новым столбцом sqft100, который равен 1/100 от столбца sqft в DataFrame storesDF? Обратите внимание, что столбца sqft100 нет в исходном DataFrame storesDF.

storeId	open	openDate	division	sqft	numberOfEmployees	customerSatisfaction
0	true	1100746394	Utah	43161	61	71.1
1	true	944572255	West Virginia	18132	96	43.46
2	false	925495628	West Virginia	79520	45	36.93
3	true	1397353092	Texas	47751	78	47.19
4	true	986505057	Delaware	81483	95	25.24
...	...	...	...	...	...	...

- A. storesDF.withColumn("sqft100", col("sqft") * 100)
- B. storesDF.withColumn("sqft100", sqft / 100)
- C. storesDF.withColumn(col("sqft100"), col("sqft") / 100)
- D. storesDF.withColumn("sqft100", col("sqft") / 100)
- E. storesDF.newColumn("sqft100", sqft / 100)

Вопрос 24: Какой из следующих блоков кода возвращает новый DataFrame из DataFrame storesDF, где столбец numberOfManagers имеет постоянное целое значение 1?

- A. storesDF.withColumn("numberOfManagers", col(1))
- B. storesDF.withColumn("numberOfManagers", 1)
- C. storesDF.withColumn("numberOfManagers", lit(1))
- D. storesDF.withColumn("numberOfManagers", lit("1"))
- E. storesDF.withColumn("numberOfManagers", IntegerType(1))

Вопрос 25: В приведенном ниже блоке кода есть ошибка. Этот блок кода предназначен для создания нового DataFrame, в котором столбец storeCategory из DataFrame storesDF разделяется по символу подчеркивания на столбцы storeValueCategory и storeSizeCategory. Найдите ошибку.

storeId	open	openDate	storeCategory
0	true	1100746394	VALUE_MEDIUM
1	true	944572255	MAINSTREAM_SMALL
2	false	925495628	PREMIUM_LARGE
3	true	1397353092	VALUE_MEDIUM
4	true	986505057	VALUE_LARGE
5	true	955988614	PREMIUM_LARGE
...	...	...	...

```
(storesDF.withColumn(  
    "storeValueCategory", col("storeCategory").split("_")[0]  
).withColumn(  
    "storeSizeCategory", col("storeCategory").split("_")[1]  
)  
)
```

Варианты ответа:

- А. Операция split() берется из импортированного объекта функций. Она принимает строковый столбец и разделитель в качестве аргументов. Она не является методом объекта Column.
- В. Операция split() берется из импортированного объекта функций. Она принимает объект Column и разделитель в качестве аргументов. Она не является методом объекта Column.
- С. Индексы 0 и 1 должны быть предоставлены в качестве вторых аргументов операции split(), а не индексировать результат.
- D. Индексные значения 0 и 1 неверны - они должны быть 1 и 2 соответственно.
- Е. Операцию withColumn() нельзя вызывать дважды подряд.

Вопрос 26: Какую из следующих операций можно использовать для разделения столбца-массива на отдельную строку DataFrame для каждого элемента массива?

- A. `extract()`
- B. `split()`
- C. `explode()`
- D. `arrays_zip()`
- E. `unpack()`

Вопрос 27: Какой из следующих блоков кода возвращает новый DataFrame, где столбец `storeCategory` является версией столбца `storeCategory` из DataFrame `storesDF` в нижнем регистре? Предполагается, что DataFrame `storesDF` - единственная определенная языковая переменная.

storeId	open	openDate	storeCategory
0	true	1100746394	VALUE_MEDIUM
1	true	944572255	MAINSTREAM_SMALL
2	false	925495628	PREMIUM_LARGE
3	true	1397353092	VALUE_MEDIUM
4	true	986505057	VALUE_LARGE
5	true	955988614	PREMIUM_LARGE
...	...	...	...

- A. `storesDF.withColumn("storeCategory", lower(col("storeCategory")))`
- B. `storesDF.withColumn("storeCategory", col("storeCategory").lower())`
- C. `storesDF.withColumn("storeCategory", tolower(col("storeCategory")))`
- D. `storesDF.withColumn("storeCategory", lower("storeCategory"))`
- E. `storesDF.withColumn("storeCategory", lower(storeCategory))`

Вопрос 28: В приведенном ниже блоке кода есть ошибка. Этот блок кода предназначен для создания нового DataFrame, где столбец `division` из DataFrame `storesDF` переименован в столбец `state`, а столбец `managerName` из DataFrame `storesDF` переименован в столбец `managerFullName`. Найдите ошибку.

```
(storesDF.withColumnRenamed("state", "division")  
  .withColumnRenamed("managerFullName", "managerName"))
```

Варианты ответа:

- A. Оба аргумента операции `withColumnRenamed()` должны быть обернуты в операцию `col()`.
- B. Операции `withColumnRenamed()` не должны вызываться дважды, и первый аргумент должен быть `["state", "division"]`, а второй аргумент должен быть `["managerFullName", "managerName"]`.
- C. Старые столбцы нужно явно удалить.
- D. Первый аргумент операции `withColumnRenamed()` должен быть старым названием столбца, а второй аргумент - новым названием столбца.
- E. Операцию `withColumnRenamed()` следует заменить на `withColumn()`.

Вопрос 29: Какой из следующих блоков кода возвращает DataFrame, из которого были удалены строки DataFrame `storesDF`, содержащие пропущенные значения в каждом столбце?

- A. `storesDF.nadrop("all")`
- B. `storesDF.na.drop("all", subset = "sqft")`
- C. `storesDF.dropna()`
- D. `storesDF.na.drop()`
- E. `storesDF.na.drop("all")`

Вопрос 30: Какая из следующих операций не возвращает DataFrame, где каждая строка уникальна?

- A. `DataFrame.distinct()`
- B. `DataFrame.drop_duplicates(subset = None)`
- C. `DataFrame.drop_duplicates()`
- D. `DataFrame.dropDuplicates()`

- E. DataFrame.drop_duplicates(subset = "all")

Вопрос 31: Какой из следующих блоков кода не всегда будет возвращать точное число различных значений в столбце division?

storeId	open	openDate	division	sqft	numberOfEmployees	customerSatisfaction
0	true	1100746394	Utah	43161	61	71.1
1	true	944572255	West Virginia	18132	96	43.46
2	false	925495628	West Virginia	79520	45	36.93
3	true	1397353092	Texas	47751	78	47.19
4	true	986505057	Delaware	81483	95	25.24
...	...	...	...	...	...	...

- A. storesDF.agg(approx_count_distinct(col("division")).alias("divisionDistinct"))
- B. storesDF.agg(approx_count_distinct(col("division"), 0).alias("divisionDistinct"))
- C. storesDF.agg(countDistinct(col("division")).alias("divisionDistinct"))
- D. storesDF.select("division").dropDuplicates().count()
- E. storesDF.select("division").distinct().count()

Вопрос 32: Какой из следующих блоков кода должен вернуть новый DataFrame со средним значением столбца sqft из DataFrame storesDF в столбце sqftMean? Выберите ответ, который правильно заполняет пропуски в блоке кода для выполнения этой задачи.

storeId	open	openDate	division	sqft	numberOfEmployees	customerSatisfaction
0	true	1100746394	Utah	43161	61	71.1
1	true	944572255	West Virginia	18132	96	43.46
2	false	925495628	West Virginia	79520	45	36.93
3	true	1397353092	Texas	47751	78	47.19
4	true	986505057	Delaware	81483	95	25.24
...	...	...	...	...	...	...

```
storesDF.__1__(__2__(__3__).alias("sqftMean"))
```

- A.
 - a. agg
 - b. mean
 - c. col("sqft")
- B.
 - a. mean
 - b. col
 - c. "sqft"
- C.
 - a. withColumn
 - b. mean
 - c. col("sqft")
- D.
 - a. agg
 - b. mean
 - c. "sqft"
- E.
 - a. agg
 - b. average
 - c. col("sqft")

Вопрос 33: Какой из следующих блоков кода возвращает количество строк в DataFrame storesDF?

- A. storesDF.withColumn("numberOfRows", count())
- B. storesDF.withColumn(count().alias("numberOfRows"))
- C. storesDF.countDistinct()
- D. storesDF.count()
- E. storesDF.agg(count())

Вопрос 34: Какой из следующих блоков кода возвращает сумму значений в столбце sqft в DataFrame storesDF, сгруппированных по отличительному значению в столбце division?

- A. storesDF.groupBy.agg(sum(col("sqft")))
- B. storesDF.groupBy("division").agg(sum())
- C. storesDF.agg(groupBy("division").sum(col("sqft")))
- D. storesDF.groupby.agg(sum(col("sqft")))
- E. storesDF.groupBy("division").agg(sum(col("sqft")))

Вопрос 35: Какой из следующих блоков кода возвращает DataFrame, содержащий сводную статистику только для столбца sqft в DataFrame storesDF?

- A. storesDF.summary("mean")
- B. storesDF.describe("sqft")
- C. storesDF.summary(col("sqft"))
- D. storesDF.describeColumn("sqft")
- E. storesDF.summary()

Вопрос 36: Какую из следующих операций можно использовать для сортировки строк DataFrame?

- A. sort() и orderBy()
- B. orderby()
- C. sort() и orderby()
- D. orderBy()
- E. sort()

Вопрос 37: Блок кода, показанный ниже, содержит ошибку. Блок кода предназначен для возврата 15-процентной выборки строк из DataFrame storesDF без замены. Определите, в чем заключается ошибка.

```
storesDF.sample(True, fraction = 0.15)
```

- A. Для параметра seed не указан аргумент.
- B. Для параметра withReplacement не указан аргумент.
- C. Операция sample() не делает выборку без замены - вместо нее следует использовать sampleby().

использовать вместо нее.

- D. Операция sample() не является воспроизводимой.
- E. Первый аргумент True устанавливает выборку с заменой.

Вопрос 38: Какую из следующих операций можно использовать для возврата первых n строк из DataFrame?

- A. DataFrame.n()
- B. DataFrame.take(n)

- C. DataFrame.head
- D. DataFrame.show(n)
- E. DataFrame.collect(n)

Вопрос 39: Какой из следующих блоков кода должен извлечь значение столбца sqft из первой строки DataFrame storesDF. Выберите ответ, который правильно заполняет пропуски в блоке кода для выполнения этой задачи.

__1__ . __2__ . __3__

- A.
 - a. storesDF
 - b. first
 - c. col("sqft")
- B.
 - a. storesDF
 - b. first
 - c. sqft
- C.
 - a. storesDF
 - b. first
 - c. ["sqft"]
- D.
 - a. storesDF
 - b. first()
 - c. sqft
- E.
 - a. storesDF
 - b. first()
 - c. col("sqft")

Вопрос 40: Какая из следующих строк кода выводит схему (структуру) DataFrame?

- A. print(storesDF)
- B. storesDF.schema
- C. print(storesDF.schema())
- D. DataFrame.printSchema()
- E. DataFrame.schema()

Вопрос 41: В каком порядке нужно выполнять приведенные ниже строки кода, чтобы создать и зарегистрировать SQL UDF с именем "ASSESS_PERFORMANCE" с помощью Python-функции `assessPerformance` и применить ее к столбцу `customerSatisfaction` в таблице `stores`?

Варианты кода:

1. `spark.udf.register("ASSESS_PERFORMANCE", assessPerformance)`
 2. `spark.sql("SELECT customerSatisfaction, assessPerformance(customerSatisfaction) AS result FROM stores")`
 3. `spark.udf.register(assessPerformance, "ASSESS_PERFORMANCE")`
 4. `spark.sql("SELECT customerSatisfaction, ASSESS_PERFORMANCE(customerSatisfaction) AS result FROM stores")`
- A. 3, 4
 - B. 1, 4
 - C. 3, 2
 - D. 2
 - E. 1, 2

Вопрос 42: В каком порядке нужно выполнять приведенные ниже строки кода, чтобы создать Python UDF `assessPerformanceUDF()` с помощью Python-функции `assessPerformance`, возвращающей целое число, и применить ее к столбцу `customerSatisfaction` в DataFrame `storesDF`?

Строки кода:

1. `assessPerformanceUDF = udf(assessPerformance, IntegerType)`
 2. `assessPerformanceUDF = spark.register.udf("ASSESS_PERFORMANCE", assessPerformance)`
 3. `assessPerformanceUDF = udf(assessPerformance, IntegerType())`
 4. `storesDF.withColumn("result", assessPerformanceUDF(col("customerSatisfaction")))`
 5. `storesDF.withColumn("result", assessPerformance(col("customerSatisfaction")))`
 6. `storesDF.withColumn("result", ASSESS_PERFORMANCE(col("customerSatisfaction")))`
- A. 3, 4
 - B. 2, 6
 - C. 3, 5
 - D. 1, 4
 - E. 2, 5

Вопрос 43: Какая из следующих операций позволяет выполнить SQL-запрос к таблице?

- A. `spark.query()`
- B. `DataFrame.sql()`
- C. `spark.sql()`
- D. `DataFrame.createOrReplaceTempView()`
- E. `DataFrame.createTempView()`

Вопрос 44: Какой из следующих блоков кода создает одностолбчатый DataFrame из Python-списка years, состоящего из целых чисел?

- A. `spark.createDataFrame([years], IntegerType())`
- B. `spark.createDataFrame(years, IntegerType())`
- C. `spark.DataFrame(years, IntegerType())`
- D. `spark.createDataFrame(years)`
- E. `spark.createDataFrame(years, IntegerType)`

Вопрос 45: Какую из следующих операций можно использовать для кэширования DataFrame только в памяти Spark, предполагая, что значения по умолчанию могут быть обновлены?

- A. `DataFrame.clearCache()`
- B. `DataFrame.storageLevel`
- C. `StorageLevel`
- D. `DataFrame.persist()`
- E. `DataFrame.cache()`

Вопрос 46: В приведенном ниже блоке кода есть ошибка. Этот блок кода предназначен для возврата нового 4-партионного DataFrame из 8-партионного DataFrame storesDF без перемешивания данных (shuffle). Найдите ошибку.

```
storesDF.repartition(4)
```

Варианты ответа:

- A. Операция repartition будет работать только в том случае, если DataFrame был кэширован в памяти.
- B. Операция repartition требует столбец, по которому выполняется разбиение, а не только количество разделов.
- C. Количество результирующих разделов, 4, недостижимо для 8-раздельного DataFrame.
- D. Операция repartition вызвала полное перемешивание (shuffle). Вместо нее следует использовать операцию coalesce().
- E. Операция repartition не может гарантировать количество разделов результата.

Вопрос 47: Какой из следующих блоков кода всегда вернет новый 12-партионный DataFrame из 8-партионного DataFrame storesDF?

- A. storesDF.coalesce(12)
- B. storesDF.repartition()
- C. storesDF.repartition(12)
- D. storesDF.coalesce()
- E. storesDF.coalesce(12, "storeId")

Вопрос 48: Какое из следующих свойств конфигурации Spark определяет количество разделов, используемых в широких преобразованиях, таких как join()?

- A. spark.sql.shuffle.partitions
- B. spark.shuffle.partitions
- C. spark.shuffle.io.maxRetries
- D. spark.shuffle.file.buffer
- E. spark.default.parallelism

Вопрос 49: В каком порядке нужно выполнять приведенные ниже строки кода, чтобы вернуть DataFrame, содержащий столбец openDateString - строковое представление даты в формате Java SimpleDateFormat?

Примечание: столбец openDate имеет целочисленный тип и представляет дату в формате UNIX-эпохи (количество секунд с полуночи 1 января 1970 года).

storeId	openDate
0	1100746394
1	1474410343
2	1116610009
3	1180035265
4	1408024997
...	...

Варианты кода:

1. `storesDF.withColumn("openDateString", from_unixtime(col("openDate"), simpleDateFormat))`
2. `simpleDateFormat = "EEEE, MMM d, yyyy h:mm a"`
3. `storesDF.withColumn("openDateString", from_unixtime(col("openDate"), SimpleDateFormat()))`
4. `storesDF.withColumn("openDateString", date_format(col("openDate"), simpleDateFormat))`
5. `storesDF.withColumn("openDateString", date_format(col("openDate"), SimpleDateFormat()))`
6. `simpleDateFormat = "wd, MMM d, yyyy h:mm a"`
 - A. 2, 3
 - B. 2, 1
 - C. 6, 5
 - D. 2, 4
 - E. 6, 1

Вопрос 50: Какой из следующих блоков кода возвращает DataFrame, содержащий столбец month, целочисленное представление месяца из столбца openDate из DataFrame storesDF?

Примечание: столбец openDate имеет целочисленный тип и представляет дату в формате UNIX-эпохи (количество секунд с полуночи 1 января 1970 года).

storeId	openDate
0	1100746394
1	1474410343
2	1116610009
3	1180035265
4	1408024997
...	...

- A. `storesDF.withColumn("month", getMonth(col("openDate")))`
- B. `storesDF.withColumn("openTimestamp", col("openDate").cast("Timestamp")).withColumn("month", month(col("openTimestamp")))`
- C. `storesDF.withColumn("openDateFormat", col("openDate").cast("Date")).withColumn("month", month(col("openDateFormat")))`
- D. `storesDF.withColumn("month", substr(col("openDate"), 4, 2))`
- E. `storesDF.withColumn("month", month(col("openDate")))`

Вопрос 51: Какая из следующих операций выполняет внутренний join двух DataFrames?

- A. `DataFrame.innerJoin()`
- B. `DataFrame.join()`
- C. Автономная (самописная) `join()` функция
- D. `DataFrame.merge()`
- E. `DataFrame.crossJoin()`

Вопрос 52: Какой из следующих блоков кода возвращает новый DataFrame, являющийся результатом внешнего соединения между DataFrame storesDF и DataFrame employeesDF по столбцу storeId?

- A. `storesDF.join(employeesDF, "storeId", "outer")`
- B. `storesDF.join(employeesDF, "storeId")`

- C. storesDF.join(employeesDF, "outer", col("storeId"))
- D. storesDF.join(employeesDF, "outer", storesDF.storeId == employeesDF.storeId)
- E. storesDF.merge(employeesDF, "outer", col("storeId"))

Вопрос 53: В приведенном ниже блоке кода есть ошибка. Этот блок кода предназначен для возврата нового DataFrame, являющегося результатом внутреннего соединения между DataFrame storesDF и DataFrame employeesDF по столбцам storeId и employeeId, которые присутствуют в обоих DataFrames. Найдите ошибку.

```
storesDF.join(employeesDF, [col("storeId"), col("employeeId")])
```

- A. Операция join() является отдельной функцией, а не методом DataFrame. Операцию join() следует вызывать так, чтобы первыми двумя аргументами были storesDF и employeesDF.
- B. Для join() должен быть третий аргумент, поскольку значение параметра how по умолчанию не является "inner".
- C. Аргументы col("storeId") и col("employeeId") не должны быть отдельными элементами списка — их нужно сравнить друг с другом, например col("storeId") == col("employeeId").
- D. Операции DataFrame.join() не существует — вместо нее следует использовать DataFrame.merge().
- E. Ссылки на "storeId" и "employeeId" не должны находиться внутри функции col() — удаление функции col() должно привести к успешному join.

Вопрос 54: Какое из следующих свойств Spark используется для настройки автоматической трансляции DataFrame без использования операции broadcast()?

- A. spark.sql.autoBroadcastJoinThreshold
- B. spark.sql.broadcastTimeout
- C. spark.broadcast.blockSize
- D. spark.broadcast.compress
- E. spark.executor.memoryOverhead

Вопрос 55: Какой из вариантов заполнения пропусков в следующем блоке кода позволит получить результат кросс-соединения (полного соединения) между DataFrame storesDF и DataFrame employeesDF?

__1__ . __2__ (__3__)

- A.
 - a. storesDF
 - b. crossJoin
 - c. employeesDF, "storeId"
- B.
 - a. storesDF
 - b. join
 - c. employeesDF, "cross"
- C.
 - a. storesDF
 - b. crossJoin
 - c. employeesDF, "storeId"
- D.
 - a. storesDF
 - b. join
 - c. employeesDF, "storeId", "cross"
- E.
 - a. storesDF
 - b. crossJoin
 - c. employeesDF

Вопрос 56: Какая из следующих операций выполняет поэлементное объединение (union) двух DataFrames?

- A. Отдельная функция concat()
- B. Отдельная функция unionAll()
- C. Отдельная функция union()
- D. DataFrame.unionByName()
- E. DataFrame.union()

Вопрос 57: Какой из следующих блоков кода записывает DataFrame storesDF в файл по пути filePath в формате parquet?

- A. storesDF.write.option("parquet").path(filePath)
- B. storesDF.write.path(filePath)

- C. storesDF.write().parquet(filePath)
- D. storesDF.write(filePath)
- E. storesDF.write.parquet(filePath)

Вопрос 58: В приведенном ниже блоке кода есть ошибка. Этот блок кода предназначен для записи DataFrame storesDF в файл по пути filePath в формате parquet с разбиением по значениям в столбце division. Найдите ошибку.

```
storesDF.write.repartition("division").parquet(filePath)
```

- A. Аргумент division для операции repartition() должен быть обернут в функцию col(), чтобы вернуть объект Column.
- B. Для DataFrameWriter не существует операции parquet() — вместо нее следует использовать операцию save().
- C. Для DataFrameWriter не существует операции repartition() — вместо нее следует использовать операцию partitionBy().
- D. DataFrame.write является операцией — за ней должны следовать круглые скобки, чтобы вернуть DataFrameWriter.
- E. Необходимо вызвать операцию mode(), чтобы указать, что эта запись не должна перезаписывать существующие файлы.

Вопрос 59: Какой из следующих блоков кода читает parquet-файл по указанному пути filePath в DataFrame?

- A. spark.read().parquet(filePath)
- B. spark.read().path(filePath, source = "parquet")
- C. spark.read.path(filePath, source = "parquet")
- D. spark.read.parquet(filePath)
- E. spark.read().path(filePath)

Вопрос 60: Какой из следующих блоков кода читает JSON-файл по указанному пути filePath в DataFrame с указанной схемой schema?

- A. spark.read().schema(schema).format(json).load(filePath)
- B. spark.read().schema(schema).format("json").load(filePath)
- C. spark.read.schema("schema").format("json").load(filePath)

- D. `spark.read.schema("schema").format("json").load(filePath)`
- E. `spark.read.schema(schema).format("json").load(filePath)`